

Dual-Line

선택적 재관측 기반 이미지 분류 시스템

독립적인 Parent/Fine 판단 상태를 공동 해석해 오류 위험을 찾고,
필요한 입력만 다시 관측한 뒤 안전하게 전환하는 추론 구조

공간 표현

위험 탐지

전환 승인

01	연구 질문과 시스템 구조	독립 Parent/Fine 표현을 공동 판단 상태로 사용하는 이유	03-05
02	모듈 설계와 수식	Backbone 계약부터 Risk, View, Candidate, Correction까지	06-17
03	판단 추적과 복구 사례	라벨 없는 런타임의 단일 사례와 공동 오답 복구	18-20
04	검증과 기여 분해	위험 탐지, 2x2 교차 실험, 독립 실행 대비 효과	21-24
05	배포 계약과 한계	서비스형 입력 경계, 확인된 범위와 확장 과제	25-26

수식 페이지와 변수 정의 페이지를 분리해 구현 논리와 tensor contract를 함께 제시합니다.

하위 정답이 상위 정답을 보장하지 않았다

상위와 하위는 의미상 계층이지만, 분류 손실은 각 과업의 차이를 학습한다.

Parent

공통 정체성에 유리한 분포

95.9%

Fine

세부 구분에 유리한 분포

93.8%

공동 정답

두 판단이 동시에 맞는 비율

92.2%


가설

두 분류기를 계층적으로 종속시키지 않고 독립 상태로 유지한 뒤, 중앙 판단기가 두 상태의 관계를 해석하면 각 과업에서 약화된 증거를 재관측과 후보 선택에 활용할 수 있다.

관찰된 상태: Parent-only 29 · Fine-only 12 · Both wrong 17 (독립 재관측 후)

두 분류기의 상태를 통합 판단 신호로 사용했다

Dual-Line의 이득은 두 모델을 보유하는 데서가 아니라, 서로 다른 판단 상태를 함께 해석하는 데서 발생한다.



Agreement

둘 다 같은 결론

Parent-only

상위만 유효

Fine-only


하위만 유효

Conflict

둘 다 위험/불일치

OOF 증거로 학습과 평가 경계를 분리했다

학습 라벨은 아티팩트 생성에만 사용하며, TEST는 모델·임계값·정책 선택에 관여하지 않는다.



검증 계약

- TEST 라벨은 모든 런타임 결정이 끝난 뒤 감사 단계에서만 결합
- TRAIN-OOF에서 REVIEW threshold와 correction 정책을 고정
- 동일 백본·후보 풀·예산 비교와 독립 서비스형 대조군을 분리 수행

반복

3 seeds


310 / 311 / 312

최종 holdout

300장

10 classes × 30

Backbone 출력을 하나의 공간 계약으로 통일했다



설정에서 Backbone 하나를 선택하며 두 모델을 동시에 사용하는 구조가 아니다.

manifest: backbone_id · preprocessing_id · feature_schema · sample_order

Backbone별 출력을 동일한 tensor contract로 정규화한다

표현 추출기만 교체하고 이후 Candidate/Gate 모듈은 동일한 shape와 sample order를 받도록 고정합니다.

기호	shape	정의와 구현 의미
F	[B, D, H, W]	ResNet 마지막 convolution feature map
P	[B, N, D]	DINOv2 native patch-token sequence
z_cls	[B, D]	전체 이미지 표현. ResNet은 GAP(F), DINOv2는 CLS token
Z_tile	[B, 16, D]	F 또는 P를 adaptive pooling하여 만든 4×4 공간 token
B / D / N	scalar	batch 크기 / embedding 차원 / native patch 수
observer_grid	4 × 4	Parent/Fine attention과 재관측 좌표가 공유하는 기준 격자

불변 조건

backbone_id, preprocessing_id, feature_schema, sample_order를 manifest에 함께 저장해 cache와 model의 조합 오류를 차단합니다.

TRAIN / OOF

Backbone별 adapter와 projector를 학습·저장

RUNTIME

z_cls와 Z_tile만 다음 모듈에 전달

Parent/Fine은 같은 입력에서 다른 증거를 만든다

독립 표현

$$\ell_{cls}^b = h_{cls}^b(z_{cls})$$
$$\ell_{tile,t}^b = W_{tile}^b z_t$$

공통 Backbone 출력에서 branch별 전역·타일 표현을 생성한다.

공간 집계

$$a_{t,c}^b = \text{softmax}_t(\ell_{tile,t,c}^b / \tau)$$
$$\ell_{pool,c}^b = \sum_t a_{t,c}^b \cdot \ell_{tile,t,c}^b$$

클래스 조건부 attention으로 16개 타일 증거를 통합한다.

학습형 결합

$$\ell^b = \alpha_b \cdot \ell_{cls}^b + (1 - \alpha_b) \cdot \ell_{pool}^b$$

전역 정체성과 공간 증거의 비율을 branch별로 학습한다.

설계 의미

Parent 공통 정체성에 필요한 증거
Fine 형제 클래스를 구분하는 세부 증거
출력 확률 + 4×4 class-conditioned attention

b: Parent/Fine branch · t: 4×4 타일 번호 · c: 클래스 번호 · τ : attention 온도 · α : 결합 비율

독립 branch는 class logit과 공간 attention을 별도로 생성한다

$b \in \{\text{Parent, Fine}\}$. 두 branch는 Backbone token만 공유하며 trainable head와 class vocabulary는 공유하지 않습니다.

기호	shape	정의와 연산
C_b	scalar	branch b 가 분류하는 클래스 수
ℓ_{cls}^b	$[B, C_b]$	z_{cls} 에서 계산한 branch b 의 전역 class logits
$\ell_{tile,t}^b$	$[B, C_b]$	t 번째 공간 token이 각 class를 지지하는 logits
$a_{t,c}^b$	$[B, 16, C_b]$	class c 기준 tile softmax weight. tile 축 합은 1
$\ell_{pool,c}^b$	$[B, C_b]$	attention으로 tile logits를 가중 합산한 공간 class logits
τ	scalar > 0	tile attention 분포의 집중도를 조절하는 temperature
α_b	$[0, 1]$	branch별 전역 logits와 공간 logits의 학습형 결합 비율
ℓ^b	$[B, C_b]$	최종 branch logits. softmax 후 Parent/Fine probability 출력

TRAIN / OOF

Parent/Fine head와 α_b 를 각 과업 loss로 학습

RUNTIME

두 확률과 class-conditioned 4x4 attention을 출력

오답 확률이 아니라 판단 상태의 위험 순위를 학습했다

02 · MODULE 03 · ERROR-RISK DETECTOR

42차원 evidence state

profile nodes · Parent/Fine distance · confidence · kNN support · normality

다중 위험 신호

$$\begin{aligned} r_{\text{branch}} &= \max(\text{rank}(q_{\text{parent}}), \text{rank}(q_{\text{fine}})) \\ r_{\text{sup}} &= \omega_d \cdot \text{rank}(q_{\text{any}}) + (1 - \omega_d) \cdot r_{\text{branch}} \\ R &= (1 - \omega_n) \cdot r_{\text{sup}} + \omega_n \cdot \text{rank}(\text{normality}) \end{aligned}$$

rank는 TRAIN-OOF score reference를 기준으로 계산한다.

선택된 ResNet18 정책

HGB depth 2 / leaf 20
 $\omega_d = 0.75 \cdot \omega_n = 0.00$
TRAIN 10% threshold = 0.9043

TEST: REVIEW 103
오답 78장 중 64장 탐지

모듈 경계

Risk Detector는 REVIEW만 요청한다. 후보 선택과 SWITCH 승인은 뒤 모듈에서 별도로 수행한다.

v233은 OOF 오류 head의 출력을 공통 백분위 위험 공간으로 결합한다

세 오류 head는 동일 evidence vector를 입력받지만 target을 분리합니다. TEST 점수는 TRAIN-OOF score 분포에 대한 percentile로 변환됩니다.

기호	범위	정의와 학습 target
q_any	[0, 1]	Parent 또는 Fine 중 하나라도 틀릴 가능성. target = parent_wrong OR fine_wrong
q_parent	[0, 1]	Parent branch가 틀릴 가능성을 예측한 OOF head 출력
q_fine	[0, 1]	Fine branch가 틀릴 가능성을 예측한 OOF head 출력
normality	real → rank	trajectory/profile가 TRAIN 정상 상태에서 이탈한 정도
rank(q)	[0, 1]	TRAIN-OOF reference에 대한 percentile. 서로 다른 head scale을 정렬
ω_d	[0, 1]	direct any-error rank와 branch maximum rank의 결합 비율
ω_n	[0, 1]	supervised risk와 normality rank의 결합 비율
R	[0, 1]	최종 REVIEW priority. TRAIN-OOF budget quantile로 threshold 고정

TRAIN / OOF

5-fold OOF로 head·가중치·Review budget threshold 선택

RUNTIME

단일 샘플의 R을 고정 threshold와 비교해 KEEP/REVIEW

Attention 연결 영역을 8개 재관측 후보로 변환했다

연결 타일 선택

$$S_0 = \{\operatorname{argmax}_t a_t\}$$
$$S_{m+1} = S_m \cup \{\operatorname{argmax}_{\{j \in N(S_m) \setminus S_m\}} a_j\}$$

현재 집합의 인접 frontier 중 attention이 가장 높은 타일로 확장한다.

관측 영역 변환

$$\text{bbox}(S, \epsilon) = \text{clip}(\text{envelope}(S) \pm \epsilon/4)$$

선택 타일의 최소 영역을 문맥 비율 ϵ 만큼 확장한다.

8개 관측 정책

01 Parent tight · $k=3, \epsilon=.10$

02 Parent context · $k=6, \epsilon=.50$

03 Fine tight · $k=3, \epsilon=.10$

04 Fine context · $k=6, \epsilon=.50$

05 Joint evidence

06 Parent/Fine disagreement

07 Secondary joint

08 Wide context

중복 bbox 제거 → 동일 Backbone stack 재사용 → 후보별 Parent/Fine 증거 생성

View Planner는 class attention의 연결 성분을 crop 좌표로 변환한다

독립 object detector가 아니라 Parent/Fine class-conditioned attention에서 시작하는 deterministic view policy입니다.

기호	타입	정의와 알고리즘 역할
a_t	16-vector	선택된 Parent/Fine class에 대한 4x4 tile attention
S_o	tile set	attention이 가장 높은 tile 하나로 초기화한 연결 집합
$N(S_m)$	tile set	현재 집합과 상하좌우 또는 대각으로 인접한 frontier
$S_{\{m+1\}}$	tile set	frontier 중 attention이 가장 높은 tile을 한 개 추가한 집합
k	integer	tight/context 정책이 선택하는 연결 tile 수
$envelope(S)$	bbox	선택 tile 집합을 덮는 최소 정규화 사각형
ϵ	[0, 1]	bbox 주변 context를 확장하는 정책별 margin
$bbox(S, \epsilon)$	[x1,y1,x2,y2]	0-1 범위로 clip된 재관측 crop 좌표

TRAIN / OOF

정책 $k \cdot \epsilon$ 와 8개 view family를 manifest로 고정

RUNTIME

REVIEW 샘플에서 crop 좌표만 생성하고 같은 stack 재사용

후보를 절대 점수가 아니라 기존 판단과의 변화로 비교했다

상대 증거 벡터

```
x_candidate = [x_conventional, z_base, z_crop, Δz,  
risk_base, risk_crop, Δrisk,  
kNN_base, kNN_crop, group_consensus]
```

Cross-view 집계

Parent/Fine 예측 일치율
후보 클래스 평균 지지도
예측 확률 엔트로피
고유 예측 비율

재관측 후보가 기존 관측보다 실제로 나아졌는지를 직접 표현한다.

재사용

모든 crop이 같은 Backbone → branch → profile → kNN 경로 사용

후보 상한

탐지한 오답 64장 중 58장은 정답 후보를 포함

Selector 과제

정답 base를 보호하면서 유효 후보를 우선순위화

Candidate vector는 base와 crop의 상대 상태 및 cross-view 합의를 보존한다

후보마다 동일한 perception/profile/kNN stack을 실행하고, crop 단독 confidence가 아니라 base 대비 변화량을 포함합니다.

x_conventional	base/candidate Parent·Fine 확률 통계, bbox와 view policy 등 기존 재관측 feature
z_base, z_crop	trajectory/profile normality model이 생성한 base 및 candidate reduced state
$\Delta z = z_{\text{crop}} - z_{\text{base}}$	재관측으로 판단 상태가 어느 방향으로 이동했는지 나타내는 상대 feature
risk_base, risk_crop, Δ risk	normality risk의 절대값과 base 대비 감소·증가
kNN_base, kNN_crop	TRAIN reference에서 Parent/Fine 이웃 지지와 거리로 계산한 membership feature
group_consensus	같은 원본의 여러 view 사이 Parent/Fine 일치율, 평균 지지, entropy, 고유 예측 비율

출력

candidate feature matrix [N_candidate, D_candidate]와 source_index, view, bbox, candidate Parent/Fine pair

TRAIN / OOF

OOF candidate rows로 correctness expert 학습

RUNTIME

REVIEW 샘플의 모든 crop 후보를 batch로 평가

여러 관측의 합의와 효용으로 전환을 승인했다

관측별 증거

$$S_v = \lambda \cdot p_{\text{joint}}(v) + (1-\lambda) \cdot v(p_{\text{parent}}(v) \cdot p_{\text{fine}}(v))$$

각 view에서 Parent/Fine 후보 쌍의 유효성을 계산한다.

후보 쌍 합의

$$A(p) = \eta \cdot \max_{\{v \in V_p\}} S_v + (1-\eta) \cdot \text{mean}_{\{v \in V_p\}} S_v + \beta \cdot |V_p| / |V|$$

같은 후보 쌍을 지지한 view의 최고·평균·반복 지지를 집계한다.

전환 승인

$$\begin{aligned} p^* &= \text{argmax}_p A(p), \quad v^* = \text{argmax}_{\{v \in V_{p^*}\}} S_v \\ \Delta U &= S_{v^*} - S_{\text{base}} \\ \text{SWITCH} &\Leftrightarrow p^* \neq p_{\text{base}} \wedge \Delta U \geq \tau \end{aligned}$$

합의로 후보 쌍을 고른 뒤 대표 view가 base보다 충분히 유효할 때만 전환한다.

ResNet18 고정 정책

λ Joint 반영 1.00
 η 최고 view 반영 0.50
 β 반복 지지 보너스 0.00
 τ SWITCH 임계값 0.05747

TRAIN-OOF 34 / 2
TEST 40 / 2
Fixed / Broken

Candidate 생성과 Transition 승인을 분리해 기존 정답을 보호한다.

v234는 view별 정답 가능성을 후보 쌍 단위 효용으로 집계한다

Parent, Fine, Joint correctness head는 OOF prediction으로 학습·보정되며, 후보 이름이나 TEST truth는 feature로 사용하지 않습니다.

기호	범위	정의와 구현 의미
$p_{parent}(v)$	$[0, 1]$	view v 의 Parent 후보가 정답일 보정 확률
$p_{fine}(v)$	$[0, 1]$	view v 의 Fine 후보가 정답일 보정 확률
$p_{joint}(v)$	$[0, 1]$	Parent와 Fine이 동시에 정답일 보정 확률
s_v	$[0, 1]$	joint 확률과 두 branch 확률의 기하평균을 λ 로 결합한 view score
$V_p \subseteq V$	view set	동일 Parent/Fine 후보 쌍 p 를 예측한 view 집합
$A(p)$	real	V_p 의 최고 score, 평균 score, 지지 비율을 $\eta \cdot \beta$ 로 집계
p^* / v^*	pair / view	$A(p)$ 가 가장 큰 후보 쌍 / 그 쌍에서 s_v 가 가장 큰 대표 view
ΔU	real	대표 view 점수 s_{v^*} 와 기존 관측 점수 s_{base} 의 차이
τ	real	OOF에서 fixed - penalty×broken을 최대화해 고정한 SWITCH threshold

TRAIN / OOF

$\lambda \cdot \eta \cdot \beta \cdot \tau$ 와 expert calibrator를 TRAIN-OOF로 선택

RUNTIME

p^* 가 base와 다르고 $\Delta U \geq \tau$ 일 때만 SWITCH

실제 입력에서 Parent 판단만 안전하게 교정했다



초기 판단

dog_like / tiger

Risk 0.9800 > threshold 0.9043



fine_context 재관측

Base validity 0.0257 → Candidate validity 0.8396



최종 판단 big_cat / tiger · SWITCH

파일명·폴더명·정답 라벨은 런타임 판단에 사용되지 않는다.

두 branch가 함께 틀린 사례도 새로운 관측으로 복구했다

04 · VALIDATION · JOINT-ERROR RECOVERY



기존 dog / german shepherd

최종 horse/horse

joint_tight · support 6



기존 dog / german shepherd

최종 dog_like/fox

fine_disagreement · support 6



기존 dog / fox

최종 deer/deer

parent_disagreement · support 4

Parent-only 14장 · Fine-only 16장 · Parent/Fine 공동 오답 10장 · 전체 Fixed 40장

1,000장 중 103장만 다시 보고 40장을 복구했다

입력

1,000

10-class TEST

REVIEW

→ 103

탐지 오답

→ 64

정답 후보

→ 58

Fixed

→ 40

정확도

Metric	Base	Final
Parent	95.9%	98.0%
Fine	93.8%	96.0%
Parent + Fine	92.2%	96.0%


전환 감사

SWITCH 50
Fixed 40
Broken 2
Wrong → Wrong 8
순증가 +38장

최종 결과는 정확도뿐 아니라 Fixed / Broken / Wrong→Wrong으로 분해해 기록했다.

동일 Review 10%에서 오답의 80.77%를 찾았다

Confidence 계열 대조군과 동일한 검토 예산으로 비교했다.



Dual-Line v233

AUROC 0.9584
AUPR 0.6780
Review 10% 탐지율 80.77%

최고 대조군 대비 +6.41%p

Parent/Fine 상태와 TRAIN-OOF 정상 분포 이탈을 함께 사용해 검토 대상의 오답 밀도를 높였다.

Risk는 적게 보게 하고, Joint Selector는 더 잘 고쳤다

동일 ResNet18 · 동일 base prediction · 동일 후보 풀에서 Risk와 Selector만 교차했다.

Risk	Selector	REVIEW	오답 밀도	Final Joint	Fixed	Broken
Independent	Independent	191	36.1%	93.1%	12	3
Independent	Joint pair	191	36.1%	95.8%	39	3
Dual v233	Independent	103	62.1%	93.3%	13	2
Dual v233	Joint v234	103	62.1%	96.0%	40	2

Dual Risk 기여

191 → 103 REVIEW

오답 밀도 36.1% → 62.1%

Joint Selector 기여

+2.7%p

Risk 고정 시 Final Joint

Full Dual-Line

96.0% · 40 / 2

정확도와 보호를 동시에 확보

독립 실행보다 적게 보고 더 많이 맞혔다



두 분류기의 서로 다른 상태를 공동 해석할 때 재관측 대상과 전환 후보를 더 효율적으로 선택했다.

시드 반복과 신규 Holdout에서 같은 방향을 재현했다

3-seed TEST1000

SEED 310

91.7 → 96.6%

Fixed / Broken 50 / 1

SEED 311

93.2 → 96.0%

Fixed / Broken 31 / 3

SEED 312

92.1 → 95.4%

Fixed / Broken 34 / 1

Wikimedia 신규 Holdout 300장

Seed	Base Joint	Final Joint	개선	Fixed / Broken
310	75.67%	86.67%	+11.00%p	36 / 3
311	76.67%	84.33%	+7.67%p	25 / 2
312	77.00%	84.67%	+7.67%p	24 / 1


평균 개선

+8.78%p

Final 85.22%

라벨 없는 실행 경로와 감사 경로를 물리적으로 분리했다

04 · DEPLOYMENT CONTRACT



Backbone별 개선 범위

ResNet18

92.2% → 96.0%

40 fixed / 2 broken

DINOv2

98.4% → 98.7%

3 fixed / 0 broken

판단 계층은 약한 Backbone에서는 큰 복구 폭을, 강한 Backbone에서는 기존 정답을 지키는 제한적 추가 개선을 보였다.

검증된 결과

- Dual risk로 REVIEW 191 → 103
- Joint selector 고정 시 +2.7%p
- 독립 실행 대비 Full +1.8%p
- 공동 오답 10장 복구

현재 범위

- 작은 객체·심한 가림에서 후보 품질 저하
- 후보가 있어도 selector가 모두 복구하지 못함
- REVIEW 경로는 추가 지연 발생
- 10-class 중심 검증

다음 확장

- 객체 크기 기반 축소·분할 view planner
- 동적 REVIEW budget과 early exit
- 외부/OOD calibration 및 class 확장
- Activation steering은 별도 검증 모듈로 유지

핵심 과제

후보를 무작정 늘리기보다, 제한된 연산 예산에서 언제 다시 보고 언제 기존 판단을 바꿀지를 안정적으로 결정하는 것