

Dual-Line 선택적 재관측 기반 이미지 분류 시스템

TRAIN-OFF 위험 탐지와 다중 전무가 보정을 결합한 선택적 추론 구조

Computer Vision · PyTorch · ResNet18 / DINOv2

[이준우] · AI / Computer Vision Engineer

GitHub Repository <https://github.com/winder34/dual-line-perception-judgment>

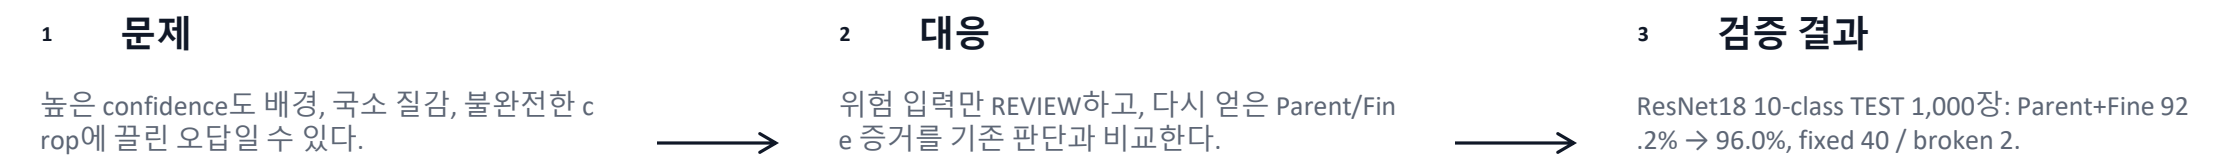
01	프로젝트 개요	문제 정의 · 학습 구조 · 추론 구조	03-05
02	핵심 모듈	표현 · 증거 · 감지 · 재관측 · 후보 · 보정	06-11
03	실행 및 검증	단일 이미지 추론 · 판단 근거 · 성능 평가	12-16
04	결과와 개선	구현 결과 · 현재 한계 · 확장 계획	17

모듈 색상 흐름

각 색상은 모듈의 역할을 나타낸다.

01	공간 표현	06
02	독립 증거	07
03	위험 감지	08
04	재관측 계획	09
05	후보 증거	10
06	전환 승인	11-15
07	실행 감사	16

관측 → 증거 → 감지 → 재관측 → 후보 → 보정 → 감사




런타임 판단 흐름

기본 예측 → 오답 위험 감지 → 선택적 재관측 → 공동 보정

설계 초점 모듈 계약 · TRAIN/TEST 경계 · 전환 감사 · label-free runtime

TRAIN/OOF 기반 학습 아티팩트 생성

학습 라벨은 아티팩트 생성 단계에서만 사용



1 · OOF 증거

각 fold의 미관측 TRAIN 예측으로 위험 감지와 보정 학습용 증거를 만든다.

2 · 저장 아티팩트

Evidence profile, v233 risk, v234 correction을 독립 아티팩트로 저장한다.

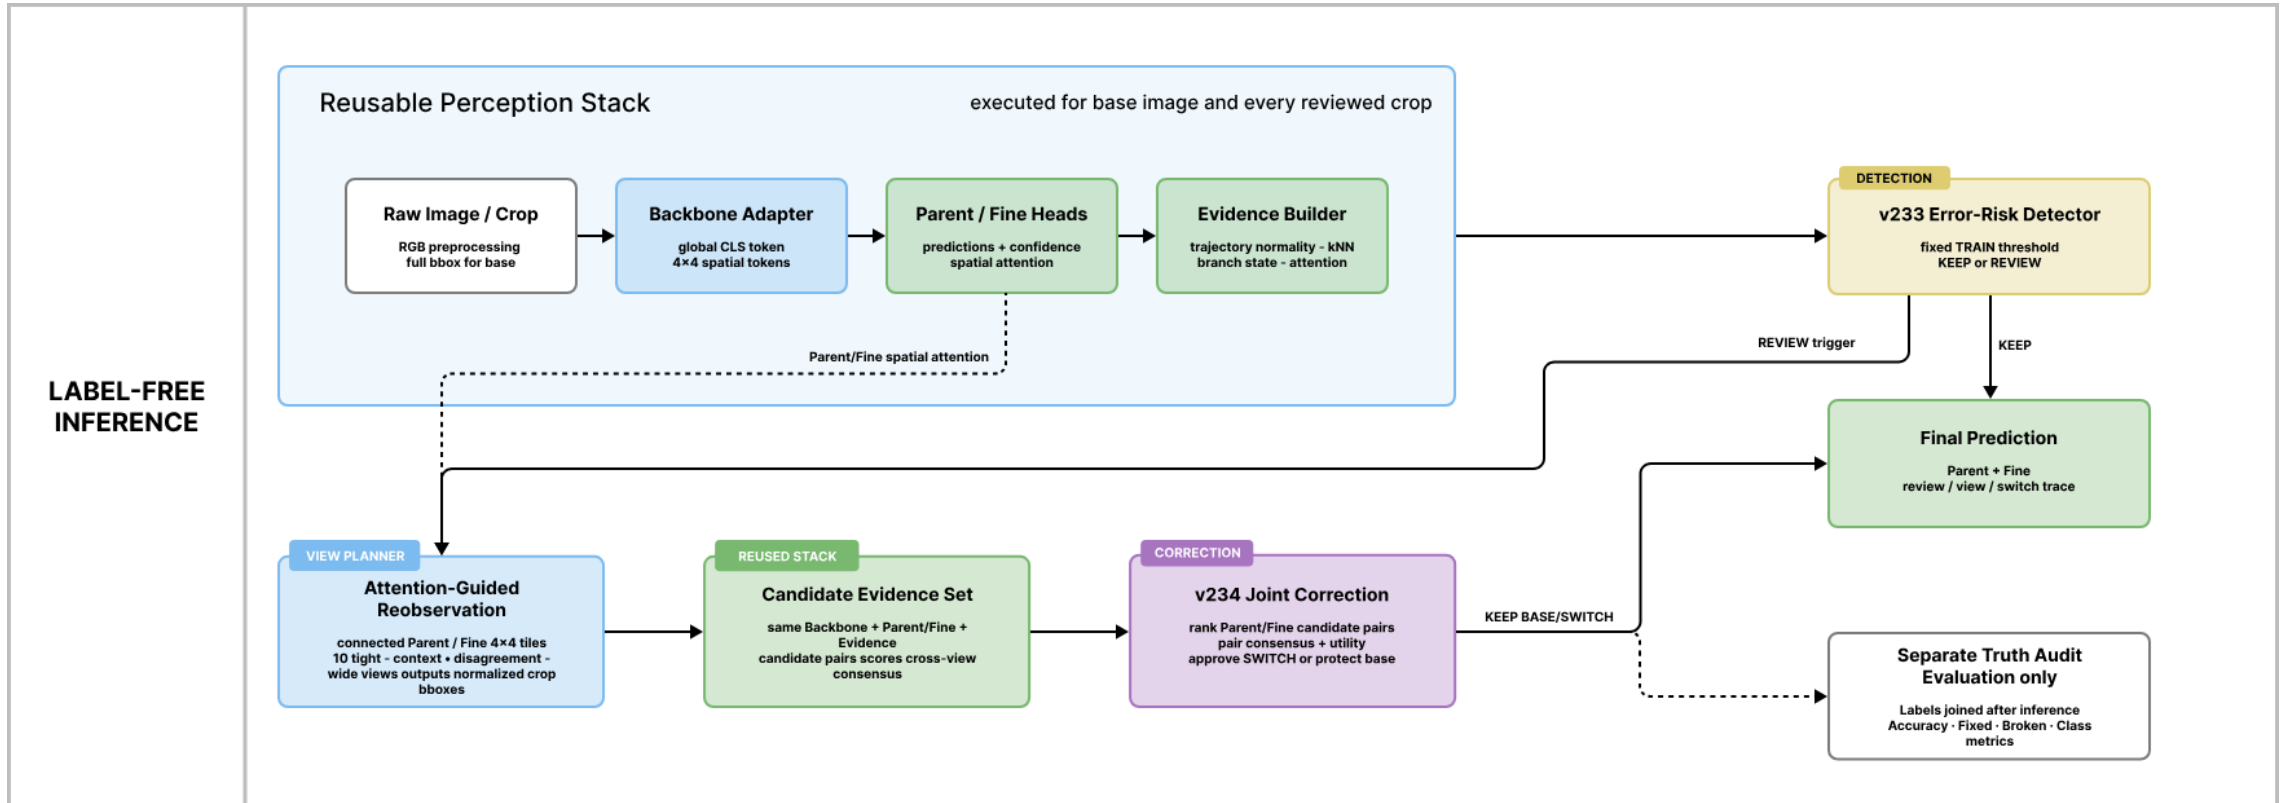
3 · TEST 경계

TEST 결과는 모델·threshold·후보 정책을 다시 선택하는 데 사용하지 않는다.

라벨 비의존 추론과 선택적 재관측

01 · LABEL-FREE RUNTIME

기본 추론 → 위험 감지 → 재관측 → 보정 → 감사



런타임은 라벨 없이 KEEP / REVIEW / SWITCH를 결정하고, 정답 라벨은 모든 판단이 끝난 뒤 별도 감사 단계에서만 결합한다.

Backbone 교체를 위한 공간 표현 통합 규격 설계


01 · 공간 표현 · 단일 BACKBONE 선택

선택지 A · ResNet

ResNet18 / 50
Final convolution map F
Adaptive average pooling

선택지 B · DINOv2

ViT-S / B
CLS + native patch tokens P
Patch grid from 14×14 patches



Backbone Spatial Adapter

ResNet: z_cls = GAP(F)
DINO: z_cls = CLS
Z_tile = Flatten(AAP_{4×4}(F or P))

Backbone 별 출력을 같은 4×4 공간 contract로 정규화

공통 출력 계약

cls_token: [B, D]
tile_tokens: [B, 16, D]
observer grid: 4×4

교체 가능한 Backbone

동시 사용이 아니라 설정으로 하나를 선택하며 candidate/gate 코드는 변경하지 않음

Stable manifest

backbone_id · preprocessing_id · feature schema · sample order를 함께 저장

Parent/Fine 독립 표현 생성과 공간 증거 결합

02 · 독립 증거 · TASK-SPECIFIC REPRESENTATION

Parent/Fine 독립 표현 생성		클래스별 공간 증거 집계	
$l_{cls}^b = h_{cls}^b(z_{cls})$ $l_{tile,t}^b = W_{tile}^b z_t$		$a_{t,c^b} = \text{softmax}_t(l_{tile,t,c^b} / \tau)$ $l_{pool,c^b} = \sum_t a_{t,c^b} \cdot l_{tile,t,c^b}$	
공통 Backbone 출력에서 Parent와 Fine이 사용할 전역 표현과 타일 표현을 각각 생성한다.		Class-conditioned attention으로 16개 tile의 증거를 통합한다.	
전역·공간 증거의 학습형 결합			
$l^b = \alpha_b \cdot l_{cls}^b + (1 - \alpha_b) \cdot l_{pool}^b$ $\alpha_b = \text{sigmoid}(\text{learned fusion logit})$		기호 및 변수 정의	
각 branch에서 전체 이미지 증와 타일 기반 공간 증거를 학습형으로 결합한다.		b Parent 또는 Fine branch t 4x4 공간에서의 타일 번호, $t \in \{1, \dots, 16\}$ c branch가 분류하는 클래스 번호 z_cls Backbone이 생성한 전체 이미지 표현 z_t Backbone이 생성한 t번째 타일 표현	
설계 의미	Parent는 공통 정체성을, Fine은 구분에 필요한 세부 증거를 복구할 수 있음		
런타임 출력	Parent/Fine probabilities + class-conditioned 4x4 spatial attention		
		l_{cls}^b branch b의 전역 class logit l_{tile,t,c^b} 타일 t에서 클래스 c를 지지하는 logit a_{t,c^b} 클래스 c에 대한 타일 t의 attention 가중치 l_{pool}^b 타일 증거를 합산한 공간 class logit l^b branch b의 최종 class logit τ attention 분포의 집중도를 조절하는 온도 α_b 전역 증거와 공간 증거의 학습형 결합 비율	

OOF 기반 오류 위험도 산출

03 · 위험 감지 · 42차원 EVIDENCE STATE

Profile node mean/std/max · Parent/Fine JS, L1, cosine · max probability · kNN support/entropy

다중 위험 신호 결합

$$\begin{aligned} r_{\text{branch}} &= \max(\text{rank}(q_{\text{parent}}), \text{rank}(q_{\text{fine}})) \\ r_{\text{sup}} &= \omega_d \cdot \text{rank}(q_{\text{any}}) + (1 - \omega_d) \cdot r_{\text{branch}} \\ R &= (1 - \omega_n) \cdot r_{\text{sup}} + \omega_n \cdot \text{rank}(\text{normality}) \end{aligned}$$

선택된 ResNet18 정책

HGB depth 2 / leaf 20
 $\omega_d = 0.75$, $\omega_n = 0.00$
TRAIN 10% budget threshold = 0.9043

런타임 rank는 TRAIN score reference를 기준으로 계산한다.

기호 및 변수 정의

OOF 선택	review budget 5% / 10% / 20%의 weighted recall과 AP, AURC로 정책 선택
TEST 감사	103장을 REVIEW하여 base-invalid 78장 중 64장 탐지 (recall 82.1%)
모듈 경계	이 모듈은 REVIEW만 요청하며 SWITCH 승인에는 관여하지 않음

q_{parent}	Parent branch가 틀릴 가능성
q_{fine}	Fine branch가 틀릴 가능성
q_{any}	둘 중 하나 이상이 틀릴 가능성
$\text{rank}(q)$	TRAIN-OOF 기준 백분위 위험 순위
normality	TRAIN의 정상 증거 분포에서 벗어난 정도
r_{branch}	두 branch 중 더 큰 오류 위험도
r_{sup}	직접 오류 탐지와 branch별 탐지를 결합한 위험도
R	최종 REVIEW 위험도
ω_d	직접 오류 탐지 q_{any} 의 반영 비율
ω_n	정상성 이탈 점수의 반영 비율

04 · 재관측 계획 · CONNECTED TOP-K

연결 타일 선택

관측 영역 변환

$$S_0 = \{ \operatorname{argmax}_t a_t \}$$
$$S_{m+1} = S_m \cup \{ \operatorname{argmax}_{\{j \in N(S_m) \setminus S_m\}} a_j \}$$

—————> $\operatorname{bbox}(S, e) = \operatorname{clip}(\operatorname{envelope}(S) \pm e / 4)$

a_t 는 타일 t 의 attention 점수, S_m 은 m 단계까지 선택된 타일 집합, $N(S_m)$ 은 S_m 에 인접한 타일 집합을 뜻한다. 인접 후보가 없으면 남은 타일 중 a_t 가 가장 높은 위치를 선택한다.

e 는 문맥 확장 비율이다. 선택 타일의 최소 사각 영역을 확장한 뒤 이미지 경계 안의 crop 좌표로 변환한다.

확장 관측 정책

기본 관측 후보

관계·충돌 기반 후보

01 Parent tight: $k=3, \epsilon=0.10$

05 Joint evidence

02 Parent context : $k=6, \epsilon=0.50$

06 Parent/Fine disagreement

03 Fine tight : $k=3, \epsilon=0.10$

07 Secondary joint

04 Fine context : $k=6, \epsilon=0.50$

08 Wide context

8개 관측 정책을 생성한 뒤 중복 bbox를 제거하고 Backbone inference를 수행한다.

재관측 후보의 비교 증거 구성

05 · 후보 증거 · 상대 비교 FEATURE

Base–Candidate 상대 증거 벡터 구성

```
x_candidate = [ x_conventional, z_base, z_crop, Δz,  
                risk_base, risk_crop, Δrisk,  
                kNN_base, kNN_crop, group_consensus ]
```

기존 판단과 재관측 후보를 예측 변화, 학습된 증거 표현, 위험도, TRAIN 이웃 지지도와 관측 간 합의 관점에서 비교해 후보 평가용 입력 벡터를 구성한다.

동일한 stack	모든 crop이 Backbone → Parent/Fine → profile → kNN 경로를 재사용
상대 상태	Δ feature로 candidate evidence를 해당 base sample과 직접 비교
후보 상한(Audit only)	탐지된 base error 64장 중 58장은 정답 Parent/Fine pair를 후보에 포함
Selector 과제	base 정답을 깨뜨리지 않으면서 유효한 증거를 순위화해야 함

관계 간 증거 집계

Parent/Fine 예측 일치율
후보 클래스 평균 지지도
예측 확률 엔트로피
고유 예측 비율

기호 및 변수 정의

$z_base, z_crop, \Delta z$
기존 관측과 재관측에서 추출한 증거 상태 및 두 상태의 변화량

$risk_base, risk_crop, \Delta risk$
기존 관측과 재관측의 정상성 이탈 위험도 및 변화량

kNN_base, kNN_crop
TRAIN의 유사한 증거 상태가 현재 예측을 얼마나 지지하는지 나타내는 값

$group_consensus$
여러 재관측 결과의 예측 일치도와 분산을 요약한 값

06 · 전환 승인 · CALIBRATED MULTI-EXPERT

관측별 증거 결합

$$S_v = \lambda \cdot p_{\text{joint}}(v) + (1 - \lambda) \cdot \sqrt{(p_{\text{parent}}(v) \cdot p_{\text{fine}}(v))}$$

Parent, Fine, Joint correctness head의 OOF 출력으로 각 view의 증거 점수를 계산한다.

후보 쌍 합의 집계

$$A(p) = \eta \cdot \max_{\{v \in V_p\}} S_v + (1 - \eta) \cdot \text{mean}_{\{v \in V_p\}} S_v + \beta \cdot |V_p| / |V|$$

동일한 Parent/Fine 쌍을 지지하는 view를 그룹화한 뒤 최고 점수, 평균 점수와 전체 view 대비 지지 비율을 집계한다.

전환 효용 평가 및 승인

$$\begin{aligned} p^* &= \text{argmax}_p A(p) \\ \Delta U &= A(p^*) - S_{\text{base}} \\ \text{SWITCH} &\Leftrightarrow p^* \neq p_{\text{base}} \wedge \Delta U \geq \tau \end{aligned}$$

최적 후보 쌍이 기존 예측과 다르고 효용 증가가 임계값 이상일 때만 전환한다.

후보 생성과 전환 승인을 서로 다른 모듈로 분리했다.

선택된 ResNet18 정책

λ Joint 점수 반영 비율	1.00
η 최고 view 점수 반영 비율	0.50
β 반복 지지 보너스	0.00
τ SWITCH 승인 임계값	0.05747

TRAIN-OOF 정책

45 switches
34 fixed / 2 broken

TEST

50 switches
40 fixed / 2 broken

기호 및 변수 정의

p Parent/Fine 후보 쌍 p^* 합의
점수가 가장 높은 후보 쌍 p_{base} 기존 Parent/Fine 예측 쌍 V_p 후보 쌍 p 를 지지한 view 집합 V 전체 재판측 view 집합 S_{base} 기존 관측의 증거 점수 ΔU 후보로 전환했을 때의 효용 증가

단일 이미지 추론 결과 및 판단 전환 기록

03 · LABEL-FREE RUNTIME · tiger_10406

06 · 전환 승인 · 실제 LABEL-FREE TRACE

01 이미지 입력

파일명과 폴더 구조에서 정답 정보를 읽지 않습니다.



download.jpg · 0.55 MB

분석 실행

02 최종 판단

278.6 ms · label-free inference

상위 개념 big_cat		세부 클래스 tiger		SWITCH
Risk score 0.9800 threshold 0.9043	Base validity 0.0257	Candidate validity 0.8396	Utility 0.8139 threshold 0.0575	

기본 판단 → Gate → 선택 view

dog_like / tiger → **SWITCH** → **fine_context**

선택 영역

A photograph of a tiger in a snowy enclosure, viewed through a wire fence. A purple bounding box is drawn around the tiger.

재관측 crop

A photograph of a tiger in a snowy enclosure, viewed through a wire fence. A green bounding box is drawn around the tiger.

06 · 전환 승인 · 후보 비교와 UTILITY

Gate 상태

Gate 상세	재관측 후보	Top-3 예측	Raw JSON
REVIEW 요청			YES
SWITCH 승인			YES
Risk			0.9800 / threshold 0.9043
Branch risk			direct 0.9578 · parent 0.9594 · fine 0.7894
Normality risk			0.5320
Validity			base 0.0257 · candidate 0.8396
Utility			0.8139 / threshold 0.0575
Chosen view			fine_context

06 · 전환 승인 · 후보 비교와 UTILITY

후보별 비교

Gate 상세	재관측 후보	Top-3 예측	Raw JSON		
View	Parent	Fine	Score	Joint	선택
fine_context	big_cat	tiger	0.8420	0.8420	선택
fine_disagreement	big_cat	tiger	0.8364	0.8364	
parent_tight	big_cat	tiger	0.8358	0.8358	
parent_context	big_cat	tiger	0.8347	0.8347	
parent_disagreement	dog_like	tiger	0.0816	0.0816	
wide_context	dog_like	tiger	0.0814	0.0814	

Top-3 예측

Gate 상세	재관측 후보	Top-3 예측	Raw JSON
Parent Top-3			
1. dog_like 47.00%			
2. deer 32.07%			
3. big_cat 17.77%			
Fine Top-3			
1. tiger 67.08%			
2. wolf 17.33%			
3. deer 6.89%			

Fine은 tiger를 유지했지만 Parent는 dog_like에 끌렸다. fine_context 재관측에서 candidate validity가 0.8396으로 상승해 Parent 전환이 승인되었다.

Local interactive demo · 실행 방법 및 필요 아티팩트는 [GitHub 저장소의 README](#) 참조

10-Class 평가 결과 및 전환 감사

03 · RESNET18 · 10-CLASS TEST · N=1,000

06 · 전환 결과 · FIXED / BROKEN AUDIT



정확도


Metric	Base	Final
Parent	95.9%	98.0%
Fine	93.8%	96.0%
Parent + Fine	92.2%	96.0%

Transition 감사

switch 50
fixed 40
broken 2
wrong→wrong 8
최종 정답 +38장

라벨 비의존 실행 및 Backbone별 결과

물리적으로 분리된 LABEL-FREE AUDIT



Backbone별 개선 범위 | 동일 10-class TEST 1,000장 기준

ResNet18	92.2% → 96.0%	40 fixed / 2 broken
DINOV2	98.4% → 98.7%	3 fixed / 0 broken

Judgment layer는 작은 Backbone에는 큰 복구 여지를, 강한 Backbone에는 보수적인 추가 이득을 제공한다.

구현 및 검증 결과, 한계 및 개선 방향

04 · RESULTS & NEXT STEPS

구현 결과 · 확인된 한계 · 향후 개선 방향

구현 결과

- Backbone 공통 출력 계약과 재사용 가능한 추론 stack
- Parent/Fine 독립 증거와 선택적 재관측
- OOF 위험 감지와 utility 기반 전환 승인
- label-free runtime과 truth audit의 물리적 분리

확인된 한계

- 작은 객체와 심한 가림에서는 관측 후보 품질이 낮음
- 재관측 후보가 있어도 selector가 모두 복구하지는 못함
- REVIEW 경로는 정확도와 교환되는 추가 지연을 발생시킴
- 10-class 중심 검증으로 도메인·클래스 확장 검증이 필요함


향후 개선 방향

- 객체 크기·가림 수준을 반영한 view planner
- early-exit와 동적 REVIEW budget으로 지연 제어
- 외부/OOD 데이터 기반 calibration 및 class 확장
- API·배치 추론·실험 manifest를 포함한 배포 패키지

핵심 과제

오답 후보를 더 많이 만드는 것보다, 제한된 연산 예산 안에서 언제 다시 보고 언제 전환할지를 안정적으로 결정하는 것

모델 성능뿐 아니라 선택·전환 과정의 재현성과 서비스 가능 조건을 분리해 검증했습니다.



검증 계약

- TEST 라벨은 모든 런타임 결정이 끝난 뒤 감사 단계에서만 결합
- TRAIN-OOF에서 임계값과 선택 정책을 고정하고 TEST에서 재조정하지 않음
- Independent / Full Dual-Line 비교는 각자 서비스 가능한 임계값으로 실행
- 동일 백본·동일 후보 풀·동일 REVIEW 예산 비교를 별도로 수행

반복 학습

3 seeds

310 / 311 / 312

최종 holdout

300장

10 classes × 30

동일 ResNet18, 동일 base prediction, 동일 7,553개 후보 풀에서 두 판단축만 교차했습니다.

Risk	Selector	REVIEW	오답 밀도	Final Joint	Fixed	Broken
Independent	Independent	191	36.1%	93.1%	12	3
Independent	Joint pair	191	36.1%	95.8%	39	3
Dual v233	Independent	103	62.1%	93.3%	13	2
Dual v233	Joint v234	103	62.1%	96.0%	40	2

Dual Risk의 역할

191 → 103 REVIEW

오답 밀도 36.1% → 62.1%

Joint Selector의 역할

+2.7%p

고정 Risk에서 Final Joint 향상

Full Dual-Line

96.0% · 40 / 2

탐지는 예산 효율, 선택기는 최종 정확도 담당

독립 실행과 Full Dual-Line 비교

Parent/Fine을 각각 서비스 가능한 파이프라인으로 실행한 뒤 교집합을 낸 경우와 공동 상태를 해석한 경우를 비교했습니다.



두 분류기를 단순 병렬로 두는 것보다, 서로 다른 판단 상태를 공동 해석할 때 더 적게 다시 보고 더 많이 맞혔습니다.

TEST1000의 상위 10%만 다시 볼 수 있다는 동일 예산에서 오류 탐지 성능을 비교했습니다.

Review 10% 오답 탐지율



v233

AUROC 0.9584
AUPR 0.6780
오답 탐지 80.77%

최고 confidence 대조군보다
오답 탐지율 +6.41%p

해석

v233은 단순 confidence 저하뿐 아니라 Parent/Fine 판단 상태와 TRAIN-OOF 정상 상태로부터의 이탈을 함께 사용해, 같은 예산에서 더 높은 오류 밀도를 만들었습니다.

백본 교체 효과를 배제하기 위해 모든 비교군을 동일 ResNet18 조건으로 맞췄습니다.

방식	REVIEW	추가 forward / image	Fine / Joint	Fixed / Broken
ResNet18 base	0	0	94.1% Fine	-
Uniform TTA 30-view	1000	+29	95.0% Fine	18 / 9
Learned TTA aggregation	1000	+29	94.4% Fine	16 / 13
Selective Uniform TTA	112	+3.248	94.9% Fine	16 / 8
Selective Learned TTA	112	+3.248	94.5% Fine	16 / 12
Dual-Line v233 + v234	103	selective	96.0% Joint	40 / 2

주: Dual-Line은 Parent/Fine 공동 정답 과제이며, Fine top-1은 동일 클래스 예측 축으로 별도 비교했습니다.

3개 시드 반복과 통계 검증

05 · VALIDATION · ROBUSTNESS

각 시드에서 전체 학습과 OOF 정책 생성을 다시 수행했습니다.

SEED 310

91.7% → 96.6%

개선 +4.9%p
Fixed / Broken 50 / 1
McNemar p = 4.62e-14

SEED 311

93.2% → 96%

개선 +2.8%p
Fixed / Broken 31 / 3
McNemar p = 7.66e-7

SEED 312

92.1% → 95.4%

개선 +3.3%p
Fixed / Broken 34 / 1
McNemar p = 2.10e-9

평균 Final Joint

96.00 ± 0.60%

세 시드 모두 개선

평균 개선

+3.67 ± 1.10%p

모든 CI가 0 초과

안전성

Broken 1 / 3 / 1

정답 보호 경향 반복

결과를 본 뒤 고르지 않은 신규 300장을 source-license-SHA와 함께 동결해 평가했습니다.

Seed	Base Joint	Final Joint	개선	Fixed / Broken	REVIEW
310	75.67%	86.67%	+11.00%p	36 / 3	97
311	76.67%	84.33%	+7.67%p	25 / 2	92
312	77.00%	84.67%	+7.67%p	24 / 1	96

평균 Final Joint

85.22%

Base 76.44%

평균 개선

+8.78%p

세 시드 CI 모두 0 초과

배포 시 관찰점

REVIEW 약 31.7%

분포 이동에서 검토 비용 증가

두 판단이 함께 틀린 사례의 복구

Fixed 40장 중 10장은 Parent와 Fine이 동시에 틀렸지만, 라벨 불일치가 아닌 위험 상태 탐지와 새 관측으로 복구했습니다.



기존 dog / german shepherd

최종 horse/horse

joint_tight · support 6



기존 dog / german shepherd

최종 dog_like/fox

fine_disagreement · support 6



기존 dog / fox

최종 deer/deer

parent_disagreement · support 4

Parent-only 복구 14장 · Fine-only 복구 16장 · Parent/Fine 공동 오답 복구 10장 · 전체 Fixed 40장

검증된 핵심

- Dual risk는 적은 REVIEW로 높은 오류 밀도 구성
- Joint selector는 동일 후보 풀에서 +2.7%p
- 독립 실행 대비 Full Dual-Line +1.8%p
- 공동 오답 10장 복구로 단순 일관성 보정과 구분

현재 한계

- 분포 이동 시 REVIEW 비율 증가
- 외부셋별 절대 이득의 크기는 다름
- 강한 백본을 항상 능가한다는 주장은 하지 않음
- 후보 생성과 선택기의 오류를 완전히 분리하지 못함

확장 실험

- Cross-branch activation steering
- TEST1000 40/2 → 42/2, 96.2%
- 외부셋에서는 개선·유지·소폭 하락 혼재
- 본체가 아닌 검증 단계의 추가 모듈로 유지

결론: Dual-Line의 이득은 두 분류기를 보유하는 데서가 아니라, 서로 다른 판단 상태를 공동 해석해 재관측 예산과 전환 결정을 제어하는 데서 발생했습니다.