

Dual-Line

선택적 재관측 분류 시스템

독립적인 Parent/Fine 판단과 위험 기반 재관측으로 오류를 줄인 Computer Vision 프로젝트



목차

문제 정의에서 통합 검증과 실행 데모까지, 결과 중심으로 구성했습니다.

01 프로젝트 개요

문제 정의 · 핵심 역량 · 수행 범위 | 03-05

03 위험 탐지

TRAIN-OOF 기반 오류 위험 순위화 | 07

05 전환 승인과 검증

다중 전문가 보정과 외부 재현 | 09

02 Dual-Line 구조

Parent/Fine 독립 판단과 그래프 통합 | 06

04 선택적 재관측

Attention 기반 관측 후보 생성 | 08

06 성과 요약과 자료

통합 결과 · GitHub · Demo | 10

문제를 구조로 바꾸고, 결과로 검증합니다

아이디어에 머무르지 않고 설계·구현·실험·문서화까지 직접 수행했습니다.

모델을 단순히 학습하는 데서 멈추지 않고,
실패 조건을 분석해 판단 구조를 설계하고 검증합
니다.

문제 발견: 오답이 발생하는 조건과 계층 간 충돌을 분리해 분석
구조 설계: Parent/Fine 독립 표현, 위험 탐지, 선택적 재관측을 연결
검증 방식: Ablation, 외부 데이터셋, 누수 검사로 효과를 확인

프로젝트 참여

1명

개인 프로젝트 · 전 과정 직접 수행

담당 범위

End-to-End

설계·구현·실험·최적화·문서화

통합 성과

+3.8%p

공동 정답률 92.2% → 96.0%

외부 검증

3개 셋

HF90 · AWA holdout · AWA wild

핵심 역량

한 프로젝트 안에서 문제 정의, 모델링, 검증, 전달까지 연결했습니다.

01 문제 정의와 실패 분석

오답 상태, branch 충돌, 데이터 오염과 분포 변화를 분리해 분석

03 선택적 추론 구조 설계

Parent/Fine 독립 판단, 위험 탐지, 재관측, 전환 승인 구현

05 파이프라인 구현·최적화

Python, PyTorch, OpenCV, NumPy, pandas, scikit-learn

02 Computer Vision 모델링

ResNet18/50, DINOv2, ROI·타일·attention 기반 표현 설계

04 실험·Ablation 검증

동일 예산 대조군, 외부셋, 누수 검사, fixed/broken 감사

06 데모·기술 문서화

라벨 없는 실행 데모, README, 실험 로그, 결과 시각화

프로젝트 수행 범위

개인 프로젝트에서 문제 정의부터 검증 자료와 실행 데모까지 직접 완성했습니다.

Dual-Line Selective Inference

Parent/Fine 독립 표현과 OOF 위험 탐지를 결합한 이미지 분류 시스템

작업기간 2026-05-21 ~ 2026-07-17

작업인원 1명 / 개인 프로젝트

작업툴 Python, PyTorch, torchvision, OpenCV, scikit-learn, NumPy, pandas, Git/
GitHub

수행 절차 데이터 구성 → 베이스라인 → 오류 분석 → 모듈 설계 → 검증
주요 산출물 학습·추론 코드, 모듈형 런타임, 로컬 데모, 기술 문서
검증 기준 정확도뿐 아니라 Fixed, Broken, Review 예산, 외부 재현성 추적


직접 수행한 파트

- 클래스별 split과 학습 데이터 구성
- Parent/Fine 및 baseline 학습
- OOF 위험 탐지와 재관측 정책 구현
- 전환 승인기와 평가 파이프라인 구현
- 속도 최적화, 데모, GitHub 문서화

왜 Dual-Line인가


상위·하위 라벨은 계층 관계지만, 각 분류 loss는 과업에 필요한 구분 특징을 따로 강화합니다.

독립 Branch 결과



Parent 95.9% · Fine 93.8% · 공동 정답률 92.2%
한쪽 branch만 맞은 샘플이 53장 존재했습니다.

설계 전환



Fine 학습에서 상위 구분 특징이 약화될 수 있어, “하위를 알면 상위도 안다”는 가정이 항상 성립하지 않습니다.

상호보완 사례

53장

Parent-only 37장 + Fine-only 16장

위험 탐지: Review 10%에서 오답 80.8% 포착

동일한 Review 예산에서 confidence 계열 대조군보다 더 많은 오류를 찾았습니다.

01 Confidence

AUROC 0.9489 · Review 10% 오답 탐지율 74.36%

02 Margin

AUROC 0.9479 · Review 10% 오답 탐지율 71.79%

03 Entropy

AUROC 0.9449 · Review 10% 오답 탐지율 67.95%


04 Dual-Line v233

AUROC 0.9584 · Review 10% 오답 탐지율 80.77%

05 대조군 대비

최고 baseline보다 오답 탐지율 +6.41%p

판단 흐름



검증 결과


두 branch의 상태와 정상성 정보를 함께 보자 위험 순위가 개선되었습니다.

선택적 재관측: 적게 보고 같은 정확도

모든 후보를 계산하는 대신, 위험도와 attention으로 필요한 관측에 연산을 집중했습니다.

관측 정책 비교

무작위 단일 view



Tight attention



무작위 관측 대비 +1.31%p

동일 Review 예산

위험 기반

97.00%


무작위 평균 94.27% 대비 +2.73%p

후보 연산 절감

전체 후보



Tight 후보



후보 78.4% 감소, 정확도 유지

결론

후보 수를 늘리는 것보다, 오답 가능성이 높은 입력과 유효한 위치를 먼저 고르는 편이 효과적이었습니다

.

검증 조건: 외부 HF90 600장 · Review 57장 · TRAIN-OOF에서 고정한 threshold 사용

전환 승인과 통합 검증

좋은 후보를 찾는 것과 기존 판단을 실제로 바꾸는 결정을 분리해 평가했습니다.

내부 TEST 1,000장

공동 정답률 92.2% → 96.0% (+3.8%p)

Review 103장 · Switch 50장

Fixed 40장 · Broken 2장 · 순개선 +38장

외부 데이터 검증

HF90 mixed 94.00% → 97.00%

AWA holdout 96.88% → 98.25%

AWA wild 6종 97.71% → 98.75%

완료한 검증

- 동일 Review 예산 대조군
- 관측 정책 Ablation
- 외부 데이터 3종
- 라벨 없는 런타임 및 누수 점검

추가 검증 예정 클래스 확장 _____ · 디바이스별 latency _____ · 검사 데이터 적용 _____

핵심 성과와 재현 자료

위험 탐지, 선택적 재관측, 전환 승인을 분리해 제한된 Review 예산에서 일관된 개선을 확인했습니다.

핵심 성과

Joint 정확도
92.2% → 96.0%

Review 10% 탐지율
80.77%

전환 품질
Fixed 40 / Broken 2

외부 검증
3개 셋 모두 개선

검증 요약

동일 Review 예산에서 confidence·margin·entropy 대조군 비교
관측 정책 Ablation과 fixed/broken 전환 감사
HF90 · AWA holdout · AWA wild 외부 재현
라벨 없는 런타임과 truth audit 물리적 분리

GitHub / Demo

github.com/winder34/dual-line-perception-judgment

라벨 없는 이미지 입력과 Review/Switch trace 확인
README · 실행 명령 · 실험 로그 제공